

@annafrick13

v2.1 Prediction System

Quantitative Football Analysis Engine

LightGBM Tweedie mit Monotonic Constraints, npxG-basiertem Feature Engineering, Dual-Track Isotonic Calibration, Dixon-Coles Matrix-Pricing, und einem Kombi-Engine fuer Same-Game Multis und Cross-Game Akkumulatoren.

0.5808	14	-1.29%	\$0
Brier Score (OOS)	Features	vs. v1 Baseline	Infrastruktur

System Details

Training Data: 38,379 matches (5 Ligen, 2017-2023)

Test Data (OOS): 1,752 matches (2023-2025)

Model: LightGBM Tweedie (power=1.0990)

Trees: 200 Home + 200 Away

Rho (Dixon-Coles): -0.0903 (optimiert)

Runtime: Browser-side Tree Traversal (TypeScript, 299 KB)

1. System-Architektur

Das @annafrick13 System ist eine End-to-End Prediction Pipeline die von historischen Understat-Daten ueber ein LightGBM Tweedie Modell zu Browser-seitiger Echtzeit-Inference fuehrt. Jede Komponente ist auf minimale Kosten und maximale mathematische Rigor optimiert.

1.1 Pipeline-Ueberblick

Stufe	Komponente	Beschreibung
1. Daten	Understat Scraper	28.718 per-Match Eintraege: npxG, PPDA, Deep Completions
2. Features	EWMA + SoS	14 Features mit striktem shift(1) — kein Look-Ahead Bias
3. Training	LightGBM Tweedie	Optuna-tuned, Monotonic Constraints, 50 Trials
4. Export	Tree JSON	Leaf-Werte als JSON, 299 KB, browser-kompatibel
5. Runtime	TypeScript Traversal	Deterministische Baum-Traversierung, exp(sum)
6. Matrix	Dixon-Coles 15x15	Bivariate Poisson mit optimiertem rho
7. Maerkte	Cell-Summierung	1X2, O/U, BTTS, CS, Exact Score aus EINER Matrix
8. Calibration	Dual-Track	Track A (Display) + Track B (Kelly/Edge)
9. Sizing	Fractional Kelly	Goldilocks 2.5-7.5%, Volatilitaets-Dampener

1.2 Design-Prinzipien

Eine Matrix, alle Maerkte: Die 15x15 Dixon-Coles Matrix ist die EINZIGE Wahrscheinlichkeitsquelle. 1X2, Over/Under, BTTS, Clean Sheet — alles durch Zellsummierung. Keine separaten Modelle, kein Double-Counting.

Monotonic Constraints: LightGBM wird physisch daran gehindert, irreale Extreme zu halluzinieren. Steigendes elo_diff MUSS hoehere Heim-Lambda produzieren. Kein Leaf-Node kann einen massiven Aussenseiter mit 4.5 erwarteten Toren vorhersagen.

Dual-Track Calibration: Track A (Roh-Matrix) bewahrt mathematische Kohaerenz zwischen Maerkten. Track B (Isotonic Regression) erzwingt historische Realitaet fuer Kelly-Sizing. Die Edge wird NUR aus Track B berechnet.

Zero Infrastructure Cost: Kein Server, kein API-Call, keine GPU. Ein statisches JSON (299 KB) + TypeScript Tree-Traversal im Browser. Deterministic, offline-faehig, latenzfrei.

2. Feature Engineering

14 Features, strikt chronologisch berechnet mit shift(1). Jedes Feature verwendet ausschliesslich Daten die VOR dem Anpfiff des zu prognostizierenden Spiels verfuegbar waren. Kein Season-Level Aggregat, kein Look-Ahead Bias.

#	Feature	Signal	Mono H/A
0	npxg_diff_ewma	Non-Penalty xG Differenz (EWMA)	+1 / -1
1	npxga_diff_ewma	Defensive npxG Differenz	-1 / +1
2	elo_diff	Elo-Rating Differenz / 400	+1 / -1
3	total_npxg	Kombinierte Angriffsstaerke	- / -
4	home_factor	Liga/Team Heimvorteil	+1 / -1
5	league_avg	Liga-Durchschnitt Tore/Spiel	- / -
6	rest_days_diff	Erholungstage Differenz / 7	+1 / -1
7	sos_strength	Strength of Schedule Differenz	- / -
8	is_derby	Binaer (25 Derby-Paarungen)	- / -
9	npxg_momentum	Akute Form vs. Saison-Baseline	+1 / -1
10	npxg_volatility	Konsistenz (Std 8-Spiele)	- / -
11	h2h_npxg_diff	Letzte 5 H2H-Begegnungen	- / -
12	ppda_ratio_diff	Pressing-Intensitaet (EWMA)	- / -
13	deep_completions_diff	Final-Third Qualitaet (EWMA)	+1 / -1

2.1 Feature Importance (Home-Modell)

npxg_volatility ist das staerkste Feature. Teams mit inkonsistenter Performance sind genuen schwerer vorherzusagen — ein Signal das ein lineares GLM nicht erfassen kann. Das Modell nutzt Volatilitaet defensiv: Hochvolatile Teams erhalten breitere Confidence-Intervalle und automatisch reduzierte Kelly-Einsaetze in Kombiwetten.

2.2 Entfernte Features

motivation_diff (Punkte zu Abstieg/Titel) wurde entfernt. Feature Importance war verdaechtig hoch (#1 mit 1051), was auf subtiles Data Leakage hindeutet — die Rekonstruktion historischer Tabellen ist anfaellig fuer Punktabzuege, Nachholspiele und Zeitgrenzen-Fehler. Das saubere 12-Feature Modell (ohne motivation) erreichte identischen Brier (0.5844 vs 0.5843). PPDA und Deep Completions haben als leakage-freie Alternativen echtes Signal beigesteuert.

3. Training & Optimierung

3.1 Optuna Hyperparameter (50 Trials)

Parameter	Wert	Bedeutung
Objective	Tweedie	Log-Link, native Overdispersion
Variance Power	1.0990	Nahe Poisson, leichte Overdispersion
Learning Rate	0.0690	Langsam + viele Trees = stabil
N Estimators	200	Anzahl Decision Trees
Max Depth	3	Flach = breite Muster, kein Overfitting
Min Data in Leaf	50	Mindestens 50 Spiele pro Blattknoten
Num Leaves	7	Begrenzte Komplexitaet pro Baum

3.2 Dixon-Coles Rho Optimierung

Der optimierte Korrelationsparameter rho = -0.0903 (v1 hatte fix -0.05). Torarme Ergebnisse (0:0, 1:0, 0:1, 1:1) korrelieren deutlich staerker als bisher angenommen. Optimiert via Bounded Scalar Minimization der Log-Loss auf diesen vier Zellen.

3.3 Brier Score Evolution

Modell	Features	Daten	Brier	Delta vs v1
v1.0 Poisson GLM	9	Goals	0.5884	Baseline
v2.0 LGB (defaults)	13	Goals	0.5887	-0.05%
v2.0 LGB (defaults)	13	npxG	0.5860	+0.41%
v2.0 LGB (Optuna 30)	13	npxG	0.5843	+0.70%
v2.0 LGB (clean)	12	npxG	0.5841	+0.73%
v2.1 LGB (PPDA+Deep)	14	npxG	0.5808	+1.29%

4. Kombi-Engine

Die Kombi-Engine nutzt die 15x15 Matrix als exakten Preismotor fuer Same-Game Multis und kombiniert Track B Calibration mit einem varianzadjustierten Kelly-Dampener fuer Cross-Game Akkumulatoren.

4.1 Same-Game Multi (SGM / BetBuilder)

Retail-Buchmacher schlagen 15-25% versteckte Marge auf BetBuilder-Quoten auf, weil normale Tipper Korrelationen nicht berechnen koennen. Die Matrix loest das exakt: Fuer jede SGM-Kombination (z.B. 'Heim + Ue2.5 + BTTS') summiert der Engine einfach alle Zellen die ALLE Bedingungen gleichzeitig erfuellen. Keine Korrelations-Schaetzung, keine Copula-Approximation — die Matrix HAT die Korrelation.

SGM-Kombination	Zell-Bedingung	Typ
Heim + Ue2.5	$h > a$ AND $h+a > 2.5$	2-Leg
Heim + BTTS	$h > a$ AND $h \geq 1$ AND $a \geq 1$	2-Leg
Heim + Ue2.5 + BTTS	$h > a$ AND $h+a > 2.5$ AND $a \geq 1$	3-Leg
Gast + Clean Sheet	$a > h$ AND $h == 0$	2-Leg
U2.5 + BTTS Nein	$h+a \leq 2$ AND ($h==0$ OR $a==0$)	2-Leg

4.2 Cross-Game Akkumulatoren

Fuer Akkumulatoren ueber verschiedene Spiele compoundiert der Engine die **Track B** (isotonisch kalibrierte) Wahrscheinlichkeiten. Ein Modell das 3% overconfident ist auf einem Einzelspiel wird bei einem 4er-Akku 12% overconfident — genug um +EV in -EV zu verwandeln. Track B erzwingt historische Realitaet.

4.3 Fractional Kelly + Volatilitaets-Dampener

Kombi-Typ	Kelly-Formel	Hard Cap
Single	$k \times 0.33$	5.0% Bankroll
2er-Akku	$k \times 0.33 / 2$	1.5% Bankroll
3er-Akku	$k \times 0.33 / 3$	1.0% Bankroll
4er-Akku	$k \times 0.33 / 4$	0.75% Bankroll
SGM (2-3 Legs)	$k \times 0.15$	2.0% Bankroll

Volatilitaets-Dampener: Wenn ein hochvolatiles Team ($np\text{pxg_volatility} > 0.8$) in einer Kombi auftaucht, wird der Kelly-Einsatz automatisch reduziert:

Volatilitaet	Schwelle	Kelly-Reduktion
Normal	< 0.8	0%
Erhoeht	$0.8 - 1.2$	-15%
Hoch	$1.2 - 1.6$	-30%
Extrem	> 1.6	-45%

5. Daten-Pipeline

Alle Daten stammen von Understat.com, gescraped via Playwright (headless Chromium). Sechs spezialisierte Scraper extrahieren verschiedene Datenschichten:

Datei	Rows	Inhalt
understat_full_matches.csv	28.718	npxG, npxBA, PPDA, Deep, Standings pro Match
understat_players.csv	22.392	Spieler-Saison: xG, npxBA, xA, xGChain, xGBuildup
understat_tactics.csv	29.548	Situation/Formation/GameState/Timing Breakdowns
understat_match_rosters.csv	426.177	Aufstellungen: per-Spieler xG/xA/Minuten
understat_match_shots.csv	362.903	Jeder Schuss: xG, Koordinaten, Situation
understat_match_stats.csv	14.434	Match-Aggregate: Schuesse, SoT, Deep, PPDA

5.1 Datenqualitaet

Alle Daten wurden stichprobenartig gegen Live-Understat-Seiten verifiziert: **93% initiale Genauigkeit**, nach Deduplizierung (parallele Scraper erzeugten Duplikate) auf **100% korrigiert**. Gesamt: 884.172 Zeilen, 116 MB, lokal gesichert.

5.2 npxBA vs. xG

Non-Penalty xG (npxBA) ist im Schnitt 8.6% niedriger als Gesamt-xG. Elfmeter-Varianz ist reines Rauschen fuer ein Vorhersagemodell — ein Team das 3 Elfmeter in 8 Spielen bekommt hat nicht ploetzlich eine staerkere Offensive. npxBA filtert dieses Rauschen und isoliert die wahre Angriffsqualitaet.

6. Guardrails & Sicherheitsmechanismen

Guardrail	Schwelle	Aktion
Monotonic Constraints	Hardcoded	Physisch unmöglich unreale Extreme zu produzieren
Lambda Clamping	[0.3, 4.5]	Kein Team erwartet < 0.3 oder > 4.5 Tore
Goldilocks Edge Guard	2.5% - 7.5%	< 2.5% = Rauschen, > 7.5% = fehlende Info
Value Trap Detection	> 7.5% vs Pinnacle	kelly=0, confidence=NONE
Dual-Track Divergenz	Track A +EV, B -EV	Warnung: Modell overconfident
Volatilitaets-Dampener	sigma > 0.8	Kelly automatisch -15% bis -45%
Feature Dimension Guard	n != 14	Prediction verweigert (null)
NaN/Infinity Guard	Jeder NaN	Prediction verweigert (null)
No LLM Fallback	Keine History	Prediction verweigert statt Garbage-In
Matrix Renormalization	sum != 1.0	Automatische Korrektur nach Dixon-Coles

7. Golden Test Verifikation

10 deterministische Test-Cases werden beim Training exportiert und bei jedem App-Start im Browser verifiziert. Die TypeScript Tree-Traversierung muss die Python-Predictions innerhalb 10^{-4} Toleranz reproduzieren.

Match	Lambda H	Lambda A
Sevilla vs Valencia (2023-08-11)	1.604	1.073
Genoa vs Napoli (2023-09-16)	0.886	1.992
Sociedad vs Mallorca (2023-10-21)	1.977	0.900
Valencia vs Celta (2023-11-25)	1.583	0.967
Werder Bremen vs RB Leipzig (2023-12-19)	1.035	2.207
Lazio vs Napoli (2024-01-28)	1.358	1.339

Alle 49 Unit-Tests bestanden. TypeScript-Kompilierung fehlerfrei. Production-deployed auf main branch.