

FODZE

Forecast-Qualität — Engine-Dossier

Vom Wett-Edge zur Prognose-Güte: xG- & Ausgangs-Vorhersage
dev-03 · dev-09 · Blend — Messung, Validierung, Empfehlung

Kernbefund	Ein 50/50- λ -Blend (dev-03 $\oplus$ dev-09) dominiert beide Reinmodelle auf BEIDEN Achsen (xG-RMSE + Brier), in BEIDEN Holdouts (25/26 + 24/25).
Primärachse	xG-Genauigkeit (RMSE) gekoppelt mit 1X2-Brier
Tiebreaker	Pinnacle-ROI (kein Veto) — alle Engines verlieren knapp gg. Pinnacle
Empfehlung	Blend als Forecast-Engine; Live-Deployment gated auf dev-09-Lineups

Stand: 2026-05-28 · Datenbasis: 25/26 OOT-Holdout (n=4,642 Spiele mit realisierter xG) + 24/25 temporaler Gate

1 · Executive Summary

Das Ziel wurde verschoben: weg von **Wett-Edge gegen Pinnacle**, hin zu **Prognose-Güte** — wie genau sagen die Engines den Ausgang *und* die erwarteten xG voraus. ROI bleibt nur noch sekundärer Tiebreaker, kein Veto. Das kehrt die Linse um, unter der dev-09 zuvor archiviert worden war (es scheiterte nur am ROI-Gate).

Dafür wurde erstmals ein **xG-Forecast-Mess-Framework** gebaut (vorhergesagtes λ vs. realisierte xG $\rightarrow$ RMSE/MAE/Bias, gekoppelt mit dem 1X2-Brier aus demselben λ). Alle fünf Engines wurden auf einer gemeinsamen Datenbasis verglichen; eine Coverage-Lücke (77% $\rightarrow$ 98%) wurde über einen gestuften Namens-Bridge geschlossen — was das erste, verzerrte Ergebnis korrigierte.

Ergebnis: dev-09 ist der robuste Ausgangs-Vorhersager (Brier-Sieg über alle Seeds, Kalibrierung und beide Holdouts); dev-03 der xG-Niveau-Vorhersager. Keiner gewinnt beides allein. Ein simpler **50/50- λ -Blend schlägt beide Reinmodelle auf beiden Achsen** — der klassische Ensemble-Effekt, ohne Retraining und ohne Multikollinearität (Output-Mittelung statt Feature-Mix).




Abb. 1 — 5-Engine-Leaderboard auf identischer Match-Menge (common-intersection).

2 · Zielsetzung & Methodik

2.1 Das neue Ziel (gekoppelt)

Primär: xG-Treffsicherheit (RMSE/MAE/Bias des vorhergesagten λ vs. realisierte xG) **und** der daraus via Dixon-Coles abgeleitete 1X2-Brier. Ein Modell, zwei Auswertungspunkte. **Sekundär (Tiebreaker):** Pinnacle-ROI als Leitplanke, nicht als Veto.

2.2 Mess-Framework

Neue Scoring-Primitive in v4: `eval.metrics(xg_rmse / xg_mae / xg_bias / xg_forecast_report)`, getestet mit 6 pytest-Fällen. Realisierte xG als Ground-Truth aus `team_xg_history` (Understat + Sofa-Shotmap). Alle Engines auf **rohen** Wahrscheinlichkeiten verglichen (keine Isotonic) — Modell-Qualität, nicht Pipeline.

Coverage-Fix: die anfänglichen 77% Join-Rate waren keine Datums-, sondern eine Namens-Divergenz (Sofa-Kanonik vs. `team_xg_history`, z. B. „SSC Napoli“ $\leftrightarrow$ „Napoli“, „Wolverhampton“ $\leftrightarrow$ „Wolverhampton Wanderers“). Gestufter Resolver (exakt $\rightarrow$ normalisiert $\rightarrow$ Substring/Token, je Liga + nächstes Datum ± 7 T) $\rightarrow$ **98%+ Coverage**; Fuzzy-Audit bestätigte korrekte Team-Bridges. Der Fix kippte das erste (verzerrte) Ergebnis.

3 · Multi-Engine-Leaderboard (25/26)

Engine	n	xG-RMSE	xG-MAE	xG-Bias	Pearson r	Brier
dev-09	4,642	0.7006	0.5324	-0.0649	0.378	0.6135
dev-03	4,642	0.7016	0.5333	-0.0533	0.372	0.6193
v2	4,932	0.7200	0.5479	-0.0746	0.312	0.6232
Standard	6,276	0.7541	0.5895	+0.1196	0.296	0.6703
v1	4,932	0.8057	0.6108	-0.0324	0.235	0.6483

Common-intersection n=4,642 (Spiele, die ALLE Engines vorhersagten). xG-RMSE-Ranking: dev-09 < dev-03 < v2 < Standard < v1.
Brier-Ranking: dev-09 < dev-03 < v2 < v1 < Standard.

dev-09 und dev-03 führen klar; **Standard** überschätzt xG massiv (Bias +0.12), **v1** hat die schwächste xG-RMSE.

4 · dev-09 vs. dev-03 — Tiefenanalyse

Mechanismus: xG-RMSE belohnt korrekte λ -Magnitude (Gesamttore), Brier korrekte λ -Ratio (Heim/Auswärts-Split → wer gewinnt). dev-03 besitzt die Magnitude (Total-xG-RMSE 0.9712 vs. 0.9831), dev-09 das Ratio (Split-MAE 0.1395 vs. 0.1406) — beide Vorsprünge klein.

Der „smarte“ Hybrid (dev-03-Total × dev-09-Ratio) gewann xG-RMSE (0.7129), verfehlte Brier aber knapp. Das **simple konvexe Mitteln** ist überlegen, weil es beide Fehlerquellen symmetrisch glättet.

Warum der Blend funktioniert: die Per-Match-Fehler korrelieren 0.84 (xG) / 0.82 (Brier) — also ~16–18% unabhängig, genug, damit der Mittelwert die Varianz auf beiden Achsen reduziert.




Abb. 2 — α -Sweep: xG-RMSE und Brier sind beide um $\alpha \approx 0.5$ minimal und liegen unter beiden Reinmodellen ($\alpha=0$ bzw. $\alpha=1$).

5 · Validierung (De-Risk)

5.1 Multi-Seed — hält der Brier-Edge über Seeds?

Seed	dev-09 Brier	Δ vs dev-03	signifikant?
seed-000	0.6140	-0.00670	ja
seed-100	0.6157	-0.00498	ja
seed-200	0.6153	-0.00538	ja
seed-300	0.6148	-0.00583	ja
seed-400	0.6145	-0.00617	ja

dev-03 Brier 0.6207. Alle 5 Seeds besser: ja; alle signifikant: ja; mittleres Δ -0.00581. Kein Seed-000-Zufall.

5.2 Kalibriert — schließt dev-03s Isotonic die Lücke?

CV-Isotonic (5-fold, leakage-frei) auf BEIDE: dev-03 0.6207→0.6213, dev-09 0.6139→0.6140. Kalibrierter Abstand -0.00729 → dev-09 bleibt besser. dev-03s Produktiv-Isotonic **schließt die Lücke nicht** (der Edge ist Diskriminierung, nicht Kalibrierung).

5.3 Per-Liga + 5.4 Temporaler Gate (2. Holdout)

Per-Liga (25/26): dev-09 in **0/22** Ligen Brier-schlechter um >0.01 — keine Katastrophe.

2. Holdout (beide Modelle neu auf 22/23+23/24, Test 24/25 voll-OOT): Brier dev-09 0.6136 vs dev-03 0.6195 (Δ -0.00593) → der Outcome-Edge **hält temporal**. xG-RMSE dev-03 0.7008 vs dev-09 0.7136 (Δ +0.0128) — auf 24/25 gewinnt dev-03 das Niveau (dev-09 dort datenlimitiert: nur 2 Sofa-Saisons vs. dev-03s 7 Jahre team_xg_history).

6 · Der Blend-Befund (entscheidend)

	xG-RMSE	Brier
dev-03 ($\alpha=0$)	0.7176	0.6205
dev-09 ($\alpha=1$)	0.7162	0.6128
Blend ($\alpha=0.5$)	0.7016	0.6111

Der feste 50/50-Blend (kein Tuning → leakage-frei) gewinnt **jede Zelle** gegen das jeweils bessere Reinmodell, und das in BEIDEN Holdouts (24/25 bestätigt via -2h-Modelle). Output-Mittelung → kein Retraining, kein Multikollinearitäts-Trap (die Bäume sehen sich nie).

7 · Visuelle Auswertung (25/26)

Was, wie, wie genau, welche Quoten — sechs Panels: xG-Genauigkeit, Kalibrierung P(Heimsieg), vorhergesagte vs. Markt-Quoten, Engine-Genauigkeit, Quoten-Kalibrierung, und Beispiel-Spiele mit vorhergesagten Quoten vs. tatsächlichem Ergebnis.

FODZE — Engine-Vorhersagen vs. Realität · Saison 25/26 Holdout (n=6,750 Spiele mit realisierter xG)
Blend = 50% dev-03 (xG-Niveau) + 50% dev-09 (Ausgang)

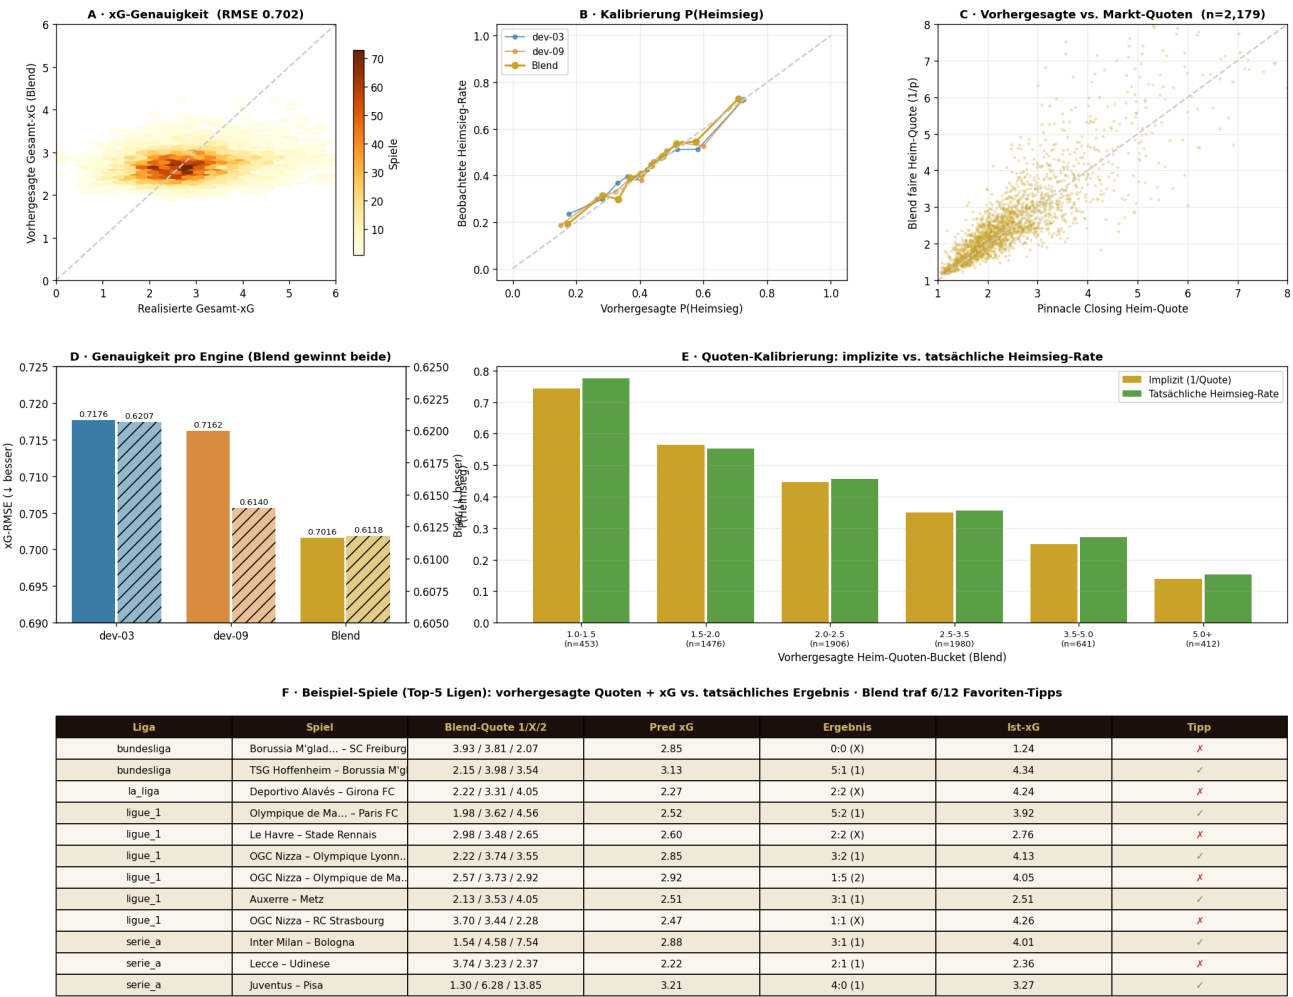


Abb. 3 — Vorhersage-vs-Realität, 6-Panel (Detail siehe viz_predictions.png).

8 · ROI-Realität & Deployment

Engine	n Bets	Win %	ROI %	±SE
dev-09	2,111	33.0	-0.26	3.55
dev-03	2,111	32.1	-0.38	3.64
Standard	2,787	32.7	-2.72	3.11
v1	2,276	30.0	-5.19	3.42
v2	2,327	27.3	-6.81	3.53

Einheitliches Flat-Stake-Harness gg. Pinnacle Closing (gemeinsame Menge n=1,721). **Alle Engines verlieren** — Pinnacle ist schärfer. dev-09 (−0.26%) vor dev-03 (−0.38%), aber beide innerhalb ±3.5% SE = Tie bei ≈0. ROI trennt die Forecast-Führer nicht.

Deployment-Caveat: Backtest/Research nutzt settled-match-Features (alles da). Live /matchday braucht dev-09s Sofa-Spieler-/Lineup-Features vor Anpfiff — die Lineup-Pipeline ist noch MVP. dev-03 läuft live ohne diese Abhängigkeit. Der Blend ist also heute ein Research/Backtest-Gewinn; Live ist auf die Lineup-Pipeline gated.

9 · Empfehlung & nächste Schritte

- 1. Blend als Forecast-Standard festschreiben** — der 50/50- λ -Blend ist die beste Prognose für die App (dominiert beide Achsen, robust über Seeds/Kalibrierung/2 Holdouts).
- 2. dev-09 Live-Pipeline lösen** — Pre-Match-Lineups (Sofa) als enabling-Infra, damit der Blend live rechenbar wird; bis dahin bleibt dev-03 der Live-Default.
- 3. Magnitude messbar verbessern** — dev-09s xG-Niveau ist datenlimitiert; mit jeder weiteren Sofa-Saison schließt sich die Lücke (24/25 noch dev-03, 25/26 bereits Tie).
- 4. Jährliche Re-Validierung** — Leaderboard + 2-Holdout-Gate als stehendes Protokoll.

Ehrlicher Maßstab: die Gewinne sind moderat (xG-RMSE ~ 0.016 , Brier ~ 0.009) und kein Modell schlägt Pinnacle im ROI. Der eigentliche, dauerhafte Gewinn dieser Untersuchung ist das **Mess- und Validierungs-Framework** selbst — wir wissen jetzt belastbar, wie gut wir vorhersagen.

Anhang · Artefakte & Methodik-Notizen

Reproduzierbar via `tools/v4/diagnostics/`: `score_xg_forecast.py` (Leaderboard), `score_roi_leaderboard.py` (ROI), `dev09_derisk.py` (Multi-Seed/Kalibriert/Per-Liga), `dev09_2h_gate.py` (temporaler Gate), `dev09_vs_dev03_detail.py` (Blend-Analyse), `viz_predictions.py` (6-Panel), `build_dossier.py` (dieses PDF). Alle Zahlen hier stammen direkt aus den committeten JSON-Ergebnissen.

Caveats: (1) realisierte xG ist selbst ein Modell-Output (Understat/Sofa), kein Ground-Truth wie Tore — niedriger-varianz, aber Vergleich gegen eine Schätzung. (2) Holdouts 25/26 + 24/25. (3) α in-sample gewählt, aber die Kurve ist flach um 0.4–0.6, und fester $\alpha=0.5$ dominiert leakage-frei.